

<회귀 실습 – 자전거 대여 수요 예측>

1. 데이터 클렌징 및 가공과 데이터 시각화

- bike_train.csv 데이터 세트를 이용해 모델을 학습한 후 대여 횟수(count) 예측
- 데이터 칼럼의 타입 보기 -> info() 사용
- 문자열을 'datetime'으로 편리하게 변환 -> 판다스의 apply 사용
- 칼럼별로 Target 값인 count(대여 횟수)의 분포 시각화 - .시본의 barplot 적용
- 다양한 회귀 모델을 데이터 세트에 적용해 예측성능측정 – RMSLE
- 함수 만들 때, log()보다는 log1p() 이용

2. 로그 변환, 피쳐 인코딩과 모델 학습/예측/평가

- 데이터 세트에 대해 먼저 처리해야 할 사항
 - (1) 결괏값이 정규 분포로 돼 있는지 확인
 - (2) 카테고리형 회귀 모델의 경우 원-핫 인코딩으로 피쳐 인코딩
- 회귀에서 큰 예측 오류가 발생할 경우, Target 값이 분포가 왜곡됐는지 확인!
- 판다스 Dataframe의 hist()를 이용해 Target 칼럼이 정규분포인지 확인
- 왜곡된 값을 정규분포로 바꾸는 방법 -> 로그를 적용해 변환
- 개별 피쳐들의 인코딩을 적용
 - (1) 사이킷런은 카테고리만을 위한 데이터 타입이 없으며, 모두 숫자로 변환
 - (2) 선형 회귀에서는 피쳐 인코딩에 원-핫 인코딩을 적용해 변환 -> pandas의 get_dummies() 이용
- 선형 회귀의 경우 중요 카테고리성 피쳐들을 원-핫 인코딩으로 변환하는 것이 성능에 중요한 영향을 미칠 수 있음

<회귀 실습 – 캐글 주택 가격 : 고급 회귀 기법>

1. 데이터 사전 처리

- 새로운 주피터 노트북을 생성하고, 생성된 디렉터리에 house_price.scv()를 이동
- 회귀 모델을 적용하기 전에 타깃 값의 분포가 정규 분포인지 확인
- 정규 분포가 아닌 결괏값을 정규 분포 형태로 변환하기 위해 로그 변환(Log Transformation) 적용
 - ➔ 넘파이의 log1p()를 이용해 로그 변환한 결괏값을 기반으로 학습
 - ➔ 다시 결괏값을 expm1()으로 추후에 환원
- 로그 변환 및 Null 피쳐의 전처리 수행
- 문자형 피쳐는 모두 원-핫 인코딩으로 변환 -> 판다스의 get_dummies() 이용

2. 선형 회귀 모델 학습/예측/평가

- 예측 결과 오류에 RMSE만 적용하면 RMSLE가 자동으로 측정됨 (타깃값인 salePrice가 로그 변환됨)
- RMSE를 측정하는 함수 생성
- 선형 회귀 모델을 학습하고 예측, 평가
- 라쏘 회귀 -> 최적 하이퍼 파라미터 튜닝 필요
- 회귀 계수 값을 가지는 판다스 Series 객체 변환 함수 만들
- 평균 RMSE 측정 -> cross_val_score() 이용
- 라쏘 모델의 경우, alpha 값 최적화 이후 예측 성능이 많이 좋아짐
- Alpha 값 최적화 후 테스트 데이터 세트의 예측 성능이 더 좋아짐
- 모델 튜닝 : 피쳐 데이터 세트의 데이터 분포도, 이상치 데이터 처리
- 대략의 데이터 가공과 모델 최적화를 수행한 뒤, 이에 기반한 여러가지 기법의 데이터 가공과 하이퍼 파라미터 기반의 모델 최적화를 반복적으로 수행하는 것이 바람직한 머신러닝 모델 생성 과정

3. 회귀 트리 모델 학습/예측/평가

- XGBoost는 XGBRegressor 클래스를, LightGBM은 LGBMRegressor클래스 이용

4. 회귀 모델의 예측 결과 혼합을 통한 최종 예측

- 개별 모델의 RMSE 값을 출력하는 get_rmse_pred() 함수 생성, 각 모델의 예측값을 계산한 뒤 개별 모델과 최종 혼합 모델의 RMSE를 구함

5. 스택킹 앙상블 모델을 통한 회귀 예측

- 개별적인 기반 모델, 최종 메타 모델 필요
- 개별 모델을 스택킹 모델로 제공하기 위해 데이터 세트를 생성하기 위한 get_stacking_base_datasets() 함수 사용